Laboratório 9 - Visualização de Dados com plotnine (diamonds)

Pedro Monteiro Tilhe - RA 254672

21/10/2026

```
import polars as pl
import pandas as pd
from datetime import datetime
from plotnine import (
    ggplot, aes, geom_point, geom_smooth, facet_wrap, facet_grid,
    scale_x_log10, scale_y_log10, scale_color_brewer, labs, theme_bw,
    theme, element_text, guides, guide_legend,
)

# Saida das tabelas em texto ASCII (compativel com o PDF)
pl.Config.set_tbl_formatting("ASCII_MARKDOWN")
pl.Config.set_tbl_hide_column_data_types(True)
pl.Config.set_tbl_hide_dataframe_shape(True)

PASTA = "../datasets/"

# Ordem natural das categorias (da pior para a melhor qualidade)
ORDEM_CUT = ["Fair", "Good", "Very Good", "Premium", "Ideal"]
ORDEM_COLOR = ["J", "I", "H", "G", "F", "E", "D"]
ORDEM_CLARITY = ["I1", "SI2", "SI1", "VS2", "VS1", "VVS2", "VVS1", "IF"]

# Eixos log10 com rotulos legiveis
ESC_X = scale_x_log10(breaks=[0.2, 0.5, 1, 2, 5])
ESC_Y = scale_y_log10(breaks=[500, 1000, 2000, 5000, 10000, 20000],
                      labels=["500", "1k", "2k", "5k", "10k", "20k"])
```

1. Importe o conjunto de dados `diamonds`, cujo arquivo está disponível no website da disciplina.

```
diamonds = pl.read_csv(
    PASTA + "diamonds.csv",
    schema_overrides={
        "cut": pl.Enum(ORDEM_CUT),
        "color": pl.Enum(ORDEM_COLOR),
        "clarity": pl.Enum(ORDEM_CLARITY),
    },
)

# plotnine usa pandas; mantemos a ordem das categorias
dpd = pd.DataFrame(diamonds.to_dict(as_series=False))
for col, ordem in [("cut", ORDEM_CUT), ("color", ORDEM_COLOR),
                   ("clarity", ORDEM_CLARITY)]:
    dpd[col] = pd.Categorical(dpd[col], categories=ordem, ordered=True)

print(diamonds.shape)
diamonds.head(5)
```

```
(53940, 10)
```

carat	cut	color	clarity	depth	table	price	x	y	z
0.23	”Ideal”	”E”	”SI2”	61.5	55.0	326	3.95	3.98	2.43
0.21	”Premium”	”E”	”SI1”	59.8	61.0	326	3.89	3.84	2.31
0.23	”Good”	”E”	”VS1”	56.9	65.0	327	4.05	4.07	2.31
0.29	”Premium”	”I”	”VS2”	62.4	58.0	334	4.2	4.23	2.63
0.31	”Good”	”J”	”SI2”	63.3	58.0	335	4.34	4.35	2.75

2. Crie uma visualização de dados que descreva a associação existente entre as variáveis peso (`carat`) e preço (`price`). Que ações você tomou para garantir que você produziu um gráfico de boa qualidade? Escreva um parágrafo comunicando os seus achados.

```
(
    ggplot(dpd, aes("carat", "price"))
    + geom_point(alpha=0.05, size=0.6, stroke=0, color="steelblue")
    + geom_smooth(method="lm", color="firebrick", se=False, size=1)
```

```
    + ESC_X + ESC_Y
    + labs(x="Peso (quilates, escala log)",
           y="Preço (USD, escala log)",
           title="Diamantes mais pesados são mais caros")
    + theme_bw()
)
```

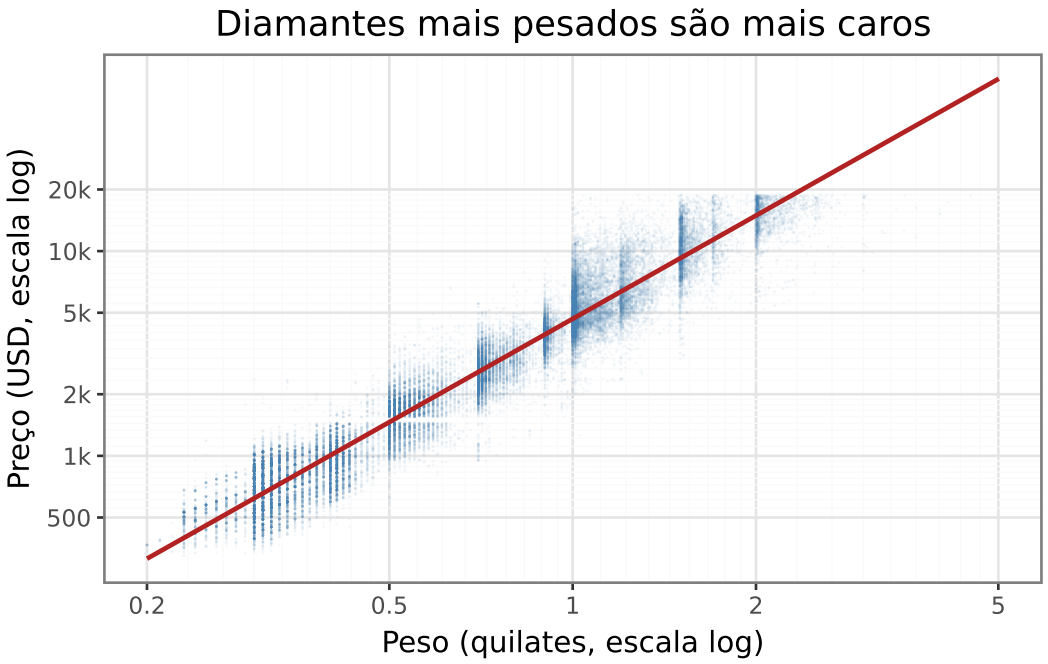


Figure 1: Preço versus peso (escala log10) com ajuste linear.

```
diamonds.select(
    pl.corr("carat", "price").round(3).alias("cor"),
    pl.corr(pl.col("carat").log10(), pl.col("price").log10())
      .round(3).alias("cor_log"),
)
```

cor	cor_log
0.922	0.966

Para evitar sobreposição dos 53.940 pontos, usei pontos pequenos e transparentes; como as variáveis são assimétricas, usei escala log10 nos dois eixos, com rótulos legíveis, título e unidades.

A associação é positiva e muito forte (correlação 0,92; 0,97 na escala log-log) e quase linear na escala log: o preço cresce mais que proporcionalmente ao peso.

3. A relação identificada na questão anterior é a mesma relação presente nos diferentes cortes de diamantes? Crie uma visualização que demonstre seus achados eficientemente. Descreva sua conclusão em um parágrafo.

```
(
    ggplot(dpd, aes("carat", "price"))
    + geom_point(alpha=0.08, size=0.5, stroke=0, color="steelblue")
    + geom_smooth(data=dpd[["carat", "price"]], method="lm", se=False,
                  fullrange=True, color="gray", linetype="dashed", size=0.8)
    + geom_smooth(method="lm", se=False, size=1, color="darkblue")
    + facet_wrap("cut", nrow=2)
    + ESC_X + ESC_Y
    + labs(x="Peso (quilates, escala log)",
           y="Preço (USD, escala log)",
           title="Preço x peso por qualidade de corte")
    + theme_bw()
)
```

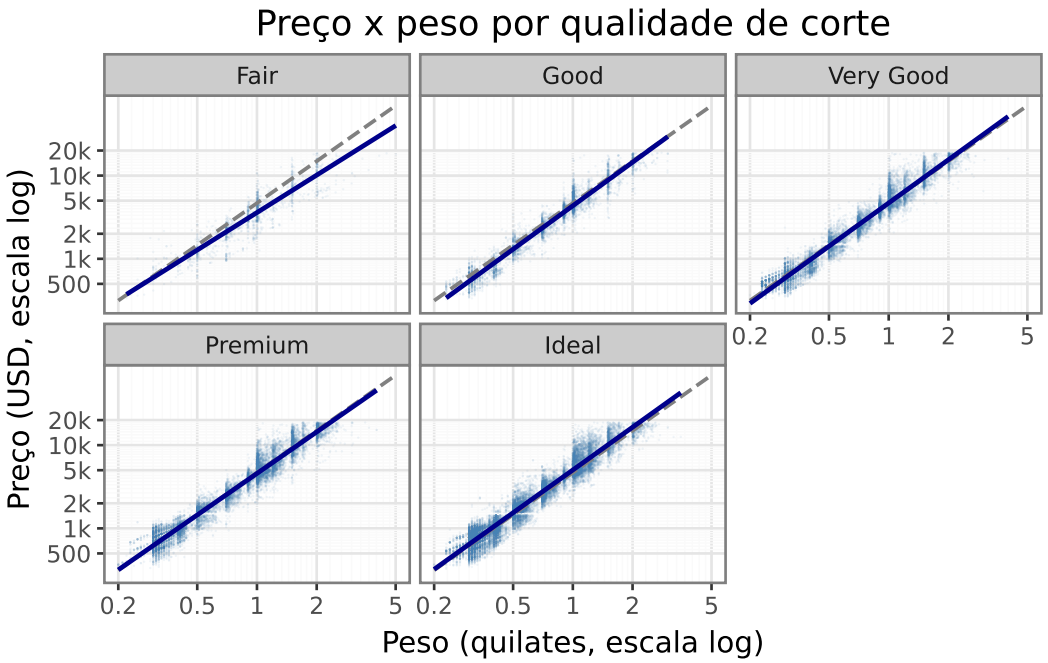


Figure 2: Preço versus peso por corte (escala log10). Linha azul: ajuste do corte; tracejada: ajuste geral.

Sim, a relação é essencialmente a mesma: em todos os cortes o preço cresce com o peso de forma linear na escala log, com retas quase paralelas à reta geral. O corte muda principalmente o nível: para um mesmo peso, cortes melhores tendem a ser um pouco mais caros, e o corte *Fair* é o que mais se afasta do padrão geral.

4. Crie uma visualização que mostre a relação entre preço e peso do diamante, considerando as diferentes combinações de qualidade de corte, cor e clareza do diamante. Quais foram as dificuldades encontradas? A relação entre preço e peso é a mesma para diferentes configurações de diamantes?

```
(
    ggplot(dpd, aes("carat", "price"))
    + geom_point(alpha=0.2, size=0.3, stroke=0, color="#999999")
    + geom_smooth(data=dpd[["carat", "price"]], method="lm", se=False,
                  fullrange=True, color="black", linetype="dashed",
                  size=0.4)
    + geom_smooth(aes(color="cut"), method="lm", se=False, size=0.6)
    + facet_grid("color ~ clarity")
```

```
    + ESC_X + ESC_Y
    + scale_color_brewer(type="qual", palette="Dark2")
    + labs(x="Peso (quilates, escala log)",
           y="Preço (USD, escala log)", color="Corte",
           title="Preço x peso por cor (linhas), clareza (colunas) e corte")
    + guides(color=guide_legend(nrow=1, override_aes={"size": 2}))
    + theme_bw()
    + theme(legend_position="bottom",
            axis_text_x=element_text(size=6, angle=90),
            axis_text_y=element_text(size=6),
            strip_text=element_text(size=8))
)
```

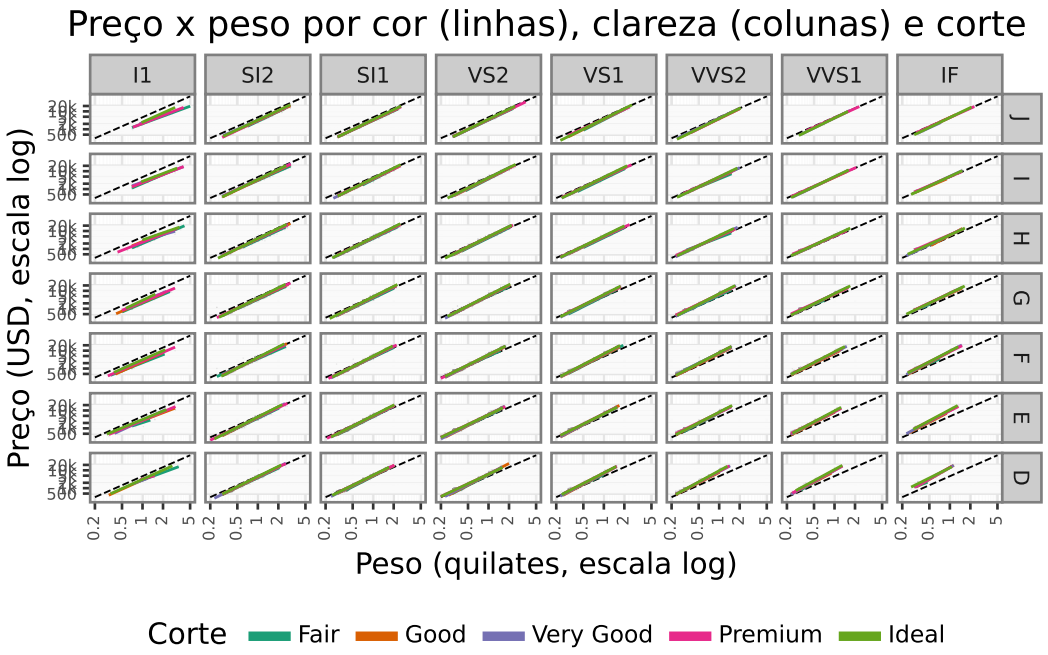


Figure 3: Preço versus peso (escala log10) por cor (linhas), clareza (colunas) e corte (cor das retas). Tracejada: ajuste geral.

As dificuldades foram o grande número de combinações (até 280), que exige 56 painéis pequenos e muita poluição visual (resolvida com pontos em cinza e só as retas coloridas), e as combinações com poucos diamantes, cujas retas são instáveis. A forma da relação se mantém, mas ela não é idêntica: dentro de cada painel os cortes quase se sobrepõem, enquanto cor e clareza deslocam as retas (melhor cor e clareza, preço mais alto para o mesmo peso), e a clareza também aumenta a inclinação.

Data e hora de compilação

21/10/2026 09:31:01